

第二章 SSA基础

2.1 基础算法

2.1.1 算法描述

2.1.1.1 第一阶段：分解

2.1.1.2 第二阶段：重构

2.1.2 对SSA基础算法中四个步骤的分析

2.1.2.1 嵌入

2.1.2.2 SVD分解

2.1.2.3 分组

第二章 SSA基础 目录

2.1 基础算法 目录

2.1.1 算法描述 目录

考虑一个长度为 N 的时间序列 $\mathbb{X} = \mathbb{X}_N = (x_1, \dots, x_N)$ 。假设 $N > 2$ 且 \mathbb{X} 是一个非零序列。用 $L(1 < L < N)$ 表示窗口长度，并且 $K = N - L + 1$ 。下面将讲述SSA的基础算法，其中包含两个阶段：分解和重构。

2.1.1.1 第一阶段：分解 目录

第一步：嵌入

我们将原始序列映射为长度为 L 的 $K = N - L + 1$ 个滞后向量，称其为L-滞后向量。

$$X_i = (x_i, \dots, x_{i+L-1})^T \quad (1 \leq i \leq K)$$

由L-滞后向量组成L-轨迹矩阵：

$$\mathbf{X} = [X_1 : \dots : X_K] = (x_{ij})_{i,j=1}^{L,K} = \begin{pmatrix} x_1 & x_2 & x_3 & \dots & x_K \\ x_2 & x_3 & x_4 & \dots & x_{K+1} \\ x_3 & x_4 & x_5 & \dots & x_{K+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_L & x_{L+1} & x_{L+2} & \dots & x_N \end{pmatrix} \quad (2.1)$$

滞后向量 X_i 是**轨迹矩阵** \mathbf{X} 的列。 \mathbf{X} 的行和列都是原序列的子序列。 \mathbf{X} 中的位于 (i, j) 的元素 $x_{ij} = x_{i+j-1}$ ，因此 \mathbf{X} 中反对角线的元素相等。（因此轨迹矩阵也被称称作**汉克尔矩阵**）公式(2.1)定义了一个从时间序列到轨迹矩阵的一对一的映射。

第二步：奇异值分解

在这一步，我们对 \mathbf{X} 进行SVD分解。令 $\mathbf{S} = \mathbf{X}\mathbf{X}^T$ 并且用 $\lambda_1, \dots, \lambda_L$ 表示 \mathbf{S} 的特征值，其中这些特征值按照从大到小的顺序排列。用 U_1, \dots, U_L 表示对应的特征向量。用 d 表示矩阵 \mathbf{X} 的秩，一般情况下，如果时间序列是真实世界中获取到的， $d = L^* = \min L, K$ 。记 $V_i = \mathbf{X}^T U_i / \sqrt{\lambda_i} (i = 1, \dots, d)$ 。轨迹矩阵 \mathbf{X} 可以被分解为：

$$\mathbf{X} = \mathbf{X}_1 + \dots + \mathbf{X}_d \quad (2.2)$$

其中 $\mathbf{X}_i = \sqrt{\lambda_i} U_i V_i^T$ 。矩阵 \mathbf{X}_i 的秩为1，这样的矩阵被称作初等矩阵（elementary matrices），集合 $(\sqrt{\lambda_i}, U_i, V_i)$ 被称作三特征（eigentriple）简记作ET。

2.1.1.2 第二阶段：重构 [目录](#)

第三步：三特征分组

一旦得到(2.2)的分解结果，就把 d 个分解结果分配到 m 个不相交的子集中 I_1, \dots, I_m 。令 $I = \{i_1, \dots, i_p\}$ 。分组 I 对应的分组结果 $\mathbf{X}_I = \mathbf{X}_{i_1} + \dots + \mathbf{X}_{i_p}$ 。最终分组后的结果记为

$$\mathbf{X} = \mathbf{X}_{I_1} + \dots + \mathbf{X}_{I_m} \quad (2.3)$$

挑选集合 I_1, \dots, I_m 的过程称作三特征分组，如果 $m = d$ ，即 $I_j = \{j\}, j = 1, \dots, d$ ，则该分组成初等分组。

第四步：对角平均

在这一步，我们需要把矩阵 \mathbf{X}_{I_j} 还原为时间序列。令 \mathbf{Y} 表示 $L * K$ 的一个矩阵，记 $L^* = \min(L, K), K^* = \max(L, K), N = L + K - 1$ 。令 $y_{ij}^* = y_{ij}$ 如果 $L < K$ ，否则 $y_{ij}^* = y_{ji}$ 。使用以下公式将矩阵 \mathbf{Y} 还原为时间序列：

$$y_k = \begin{cases} \frac{1}{k} \sum_{m=1}^k y_{m,k-m+1}^* & \text{for } 1 \leq k < L^*, \\ \frac{1}{L^*} \sum_{m=1}^{L^*} y_{m,k-m+1}^* & \text{for } L^* \leq k \leq K^*, \\ \frac{1}{N-k+1} \sum_{m=k-K^*+1}^{N-K^*+1} y_{m,k-m+1}^* & \text{for } K^* < k \leq N. \end{cases} \quad (2.4)$$

该公式对应着求取矩阵反对角线元素的平均值。

对 \mathbf{X}_{L_k} 使用对角平均可以得到重构序列 $\tilde{\mathbf{X}}^{(k)} = (\tilde{x}_1^{(k)}, \dots, \tilde{x}_N^{(k)})$ 。最终，初始序列被分解为 m 成分：

$$x_n = \sum_{k=1}^m \tilde{x}_n^{(k)} \quad (n = 1, 2, \dots, N) \quad (2.5)$$

由初等分组得到的序列重构结果被称作初等重构序列 (elementary reconstructed series)。

Remark 2.1 基础SSA算法可以自然扩展到复数时间序列：唯一的区别在于矩阵的转置要替换为复数的共轭转置。

2.1.2 对SSA基础算法中四个步骤的分析 目录

SSA基础算法中的步骤需要一些说明。在这个部分我们简要讨论所涉及的程序的含义。

2.1.2.1 嵌入 目录

嵌入是一个把一维时间序列 $\mathbb{X} = (x_1, \dots, x_N)$ 使用向量 $X_i = (x_i, \dots, x_{i+L-1})$ 转换为多维序列 X_1, \dots, X_K 的过程，其中 $K = N - L + 1$ 。嵌入的参数是窗口长度 L 。注意轨迹矩阵(2.1)具有明显的对称性。 \mathbb{X}^T 相当于是窗口长度为 K 的多维序列。

对于动力系统专家来说，一种常用的技术是获得所有成对的滞后向量 \mathbf{X}_i 和 \mathbf{X}_j 之间的经验，然后计算时间序列相关的维度。该维数与产生时间序列的动力系统的吸引子的分形维数有关。需要注意的是，在这种方法中， L 必须相当小而 K 相当大。同样，在具有汉克尔矩阵结构的结构总最小二乘 (Structural Total Least Squares) 中，通常的做法是选择 $L = r + 1$ ，其中 r 是近似矩阵的猜测秩。

在SSA中，窗口长度 L 应该足够大。特别是， L 必须足够大，以便每个 L 滞后向量包含初始序列 $\mathbb{X} = (x_1, \dots, x_N)$ 的一个基础部分。 L 必须足够大时，才有可能将每个 L 滞后向量 \mathbf{X}_i 视为一个单独的序列。

2.1.2.2 SVD分解 目录

SVD分解可以使用不同的术语被描述，并且可以被用于不同的目的。让我们从SVD一般的特点开始讲解，这些特点对于理解SSA十分重要。

正如我们已经提到过的，SVD分解可以对任意的维度为 $L * K$ 的矩阵 $\mathbf{X} = [X_1 : \dots X_K]$ 进行分解，分解形式如下：

$$\mathbf{X} = \sum_{i=1}^d \sqrt{\lambda_i} U_i V_i^T \quad (2.6)$$

其中 $\lambda_i (i = 1, \dots, L)$ 是矩阵 $\mathbf{S} = \mathbf{X}\mathbf{X}^T$ 的特征值，并且按照递减的顺序进行排列。 $d = \max\{i, \text{such that } \lambda_i > 0\} = \text{rank}(\mathbf{X})$ ， $\{U_1, \dots, U_d\}$ 是 \mathbf{S} 的正交特征向量，并且 $V_i = \mathbf{X}^T U_i / \sqrt{\lambda_i}$ 。

标准的SVD术语称 $\sqrt{\lambda_i}$ 为奇异值； U_i 和 V_i 为矩阵 \mathbf{X} 的左奇异向量和右奇异向量。如果我们定义 $\mathbf{X}_i = \sqrt{\lambda_i} U_i V_i^T$ ，那么公式(2.6)可以被写作公式(2.2)的形式。

如果所有特征向量的重数为1，那么展开式(2.2)是唯一确定的。否则，如果至少有一个特征值的重数大于1，那么在选择相应的特征向量时就有了自由度。我们应该假设以某种方式选择特征向量并且选择是固定的。

公式(2.6)说明SVD分解具有以下的对称性： V_1, \dots, V_d 构成了矩阵 $\mathbf{X}^T \mathbf{X}$ 的特征正交系统。注意到轨迹矩阵的行和列都是原时间序列的子序列，因此左右奇异向量都具有时间结构，所以这些奇异向量也可以看做时间序列。

SVD分解具有很多特征，其中一个如下：在所有秩 $r < d$ 的矩阵 $\mathbf{X}^{(r)}$ 中，矩阵 $\sum_{i=1}^r \mathbf{X}_i$ 给出了对轨迹矩阵 \mathbf{X} 的最优估计，即 $\|\mathbf{X} - \mathbf{X}^{(r)}\|_F$ 最小。其中 F 表示矩阵的Frobenius范数，一个矩阵 \mathbf{Y} 的Frobenius范数为 $\|\mathbf{Y}\|_F = \sqrt{\langle \mathbf{Y}, \mathbf{Y} \rangle_F}$ 。其中两个矩阵 $\mathbf{Y} = \{y_{ij}\}_{i,j=1}^{q,s}$ 和 $\mathbf{Z} = \{z_{ij}\}_{i,j=1}^{q,s}$ 的内积定义为：

$$\langle \mathbf{Y}, \mathbf{Z} \rangle_F = \sum_{i,j=1}^{q,s} y_{ij} z_{ij}$$

对于向量而言，Frobenius范数等同于传统的欧几里得范数。

注意到 $\|\mathbf{X}\|_F^2 = \sum_{i=1}^d \lambda_i$ 并且 $\lambda_i = \|\mathbf{X}_i\|_F^2$ ，因此我们考虑将 $\lambda_i / \|\mathbf{X}\|_F^2$ 作为度量矩阵 \mathbf{X}_i 在整个轨迹矩阵 \mathbf{X} 中所占的比重。最终可以使用 $\sum_{i=1}^r \lambda_i / \|\mathbf{X}\|_F^2$ 作为轨迹矩阵的最优近似的特征指标。而且，如果 $\lambda_r \neq \lambda_{r+1}$ ，可以把 $\sum_{i=r+1}^d \lambda_i$ 作为轨迹矩阵与其最优估计之间的误差距离。

现在我们考虑把轨迹矩阵 \mathbf{X} 看做是一系列 L 延时的向量。用 $\mathcal{X}^{(L)} \subset \mathbb{R}^L$ 表示向量 X_1, \dots, X_K 组成的线性空间。我们把这个空间称作时间序列 \mathbb{X} 的 L -轨迹空间。为了强调序列 \mathbb{X} 的作用，我们把这个空间记作 $\mathcal{X}^{(L)}(\mathbb{X})$ 。公式(2.6)表明 $\mathcal{U} = (U_1, \dots, U_d)$ 是这个轨迹空间的一组正交基向量。

令 $Z_i = \sqrt{\lambda_i} V_i, i = 1, \dots, d$, 公式(2.6)可以被写作 $\mathbf{X} = \sum_{i=1}^d U_i Z_i^T$, 并且对于延时向量 X_j 我们有 $X_j = \sum_{i=1}^d z_{ji} U_i$, 其中 z_{ji} 是向量 Z_i 中的元素。这意味着向量 Z_i 是由向量 X_j 在基向量 \mathcal{U} 下的第 i 个成分组成的。

让我们考虑转置的轨迹矩阵 \mathbf{X}^T 。引入 $Y_i = \sqrt{\lambda_i} U_i$, 我们可以得到展开式 $\mathbf{X}^T = \sum_{i=1}^d V_i Y_i^T$, 该公式对应着 K -延时向量在正交基 V_1, \dots, V_d 下的表示。至此, SVD分解引出了关于轨迹矩阵 \mathbf{X} 的两种几何描述。

上述关于SVD特性的描述可以用 L 延时向量的多变量几何语言进行描述, 如下: 令 $r < d$, 那么在整个 r 维子空间 \mathcal{L}_r 中, 由 U_1, \dots, U_r 张成的子空间可以最好得估计原空间。也就是说, 最小化 $\sum_{i=1}^K \text{dist}^2(X_i, \mathcal{L}_r)$ 得到结果是 $\mathcal{L}_r = \text{span}(U_1, \dots, U_r)$, 而 $\sum_{i=1}^r \lambda_i / \sum_{i=1}^d \lambda_i$ 是这些延时向量的 r 维最佳估计的特征。

SVD的另一个特征与特征向量 U_1, \dots, U_d 有关。具体地, 第一个特征向量 U_1 决定了延时向量的投影变化最大的方向。后续的每一个特征向量都与之前的特征向量正交, 并且延时向量在该方向上的投影变化也是最大的。因此, 很自然地将第 i 个特征向量所表示的方向称作第 i 个主方向。注意到, 矩阵 $\mathbf{X}_i = U_i Z_i^T$ 是延时向量在第 i 个主方向投影后构成的。

这种对于SVD分解的理解角度引出了以下的术语。我们称向量 U_i 为第 i 个主特征向量, 向量 V_i 和 $Z_i = \sqrt{\lambda_i} V_i$ 被称作第 i 个音字向量和第 i 个主成分。

Remark 2.2: SSA基础算法中所使用的SVD分解类似于经典的多变量分析中的主成分分析 (PCA) 和平稳时间序列分析中的KL变换。然而, SSA中的SVD方法利用了轨迹矩阵具有汉克尔结构的特点。事实上, 轨迹矩阵的行和列都是原始序列的子序列并具有相同的时域意义, 而PCA和KL变换并非如此。

Remark 2.3: 一般地, 轨迹空间中的任何一组正交基 P_1, \dots, P_d 都可以替代通过SVD分解得到的正交基 U_1, \dots, U_d 。在这种情况下, 公式(2.2)可以被替换为 $\mathbf{X}_i = P_i Q_i^T$, 其中 $Q_i = \mathbf{X}^T P_i$ 。一种可以替换正交基的例子是, 在拓普利兹SSA中的自相关矩阵中的正交基, 见章节2.5.3。另一个例子可以在独立成分分析 (ICA) 和因子分析中看到, 见章节2.5.4。

关于SVD进一步的讨论以及使用见章节2.5.7。

2.1.2.3 分组 目录

分组这一步骤是对公式(2.2)中的 \mathbf{X}_i 进行分组分配。假设 $m = 2$, $I_1 = I = \{i_1, \dots, i_r\}$ 并且 $I_2 = \{1, \dots, d\} \setminus I$, 其中 $1 \leq i_1 < \dots < i_r \leq d$ 。

分组的目的是对时间序列的附加成分进行划分。假设时间序列 \mathbb{X} 是两个时间序列 $\mathbb{X}^{(1)}$ 和 $\mathbb{X}^{(2)}$ 的和; 也就是说 $x_i = x_i^{(1)} + x_i^{(2)}, i = 1, \dots, N$ 。固定窗口长度 L 并且用 $\mathbf{X}, \mathbf{X}^{(1)}, \mathbf{X}^{(2)}$ 分别表示时间序列 $\mathbb{X}, \mathbb{X}^{(1)}, \mathbb{X}^{(2)}$ 的 L 的轨迹矩阵。考虑轨迹矩阵 \mathbb{X} 的SVD分解。如果存在一组下标 $I \subset \{1, \dots, d\}$, 使得 $\mathbf{X}^{(1)} = \sum_{i \in I} \mathbf{X}_i$ 并且 $\mathbf{X}^{(2)} = \sum_{i \notin I} \mathbf{X}_i$, 那么我们称 $\mathbb{X}^{(1)}$ 和 $\mathbb{X}^{(2)}$ 是 (弱) 可分的。在这个例子中, $\mathbb{X}^{(1)}$ 在整个时间序列中的贡献值为对应的特征值的比重 $\sum_{i \in I} \lambda_i / \sum_{i=1}^d \lambda_i$ 。

(这里由两个小段没有翻译，感觉不是很必要)

分组的目的是找到一组分组方案 I_1, \dots, I_m ，它们对应的轨迹矩阵 $\mathbf{X}_{I_1}, \dots, \mathbf{X}_{I_m}$ 具有汉克尔矩阵的结构。 (主要注意公式(2.2)中对轨迹矩阵分解以后，分解后的成分可能不具有汉克尔矩阵的结构，而分组这一步骤正是为了让各个成分具有汉克尔矩阵的结构)

现在让我们从多变量几何的角度看分组这一步骤。令 $\mathbf{X} = [X_1 : \dots : X_K]$ 表示时间序列 \mathbb{X} 的轨迹矩阵，序列 $\mathbb{X}^{(1)}$ 和 $\mathbb{X}^{(2)}$ 是一组分解方式并且各自对应下标集合 I 和 $\{1, \dots, d\} \setminus I$ 。这意味着由基向量 U_1, \dots, U_d 张成的轨迹空间 $\mathcal{X}^{(L)}$ 被分为了两个部分，即 $\mathcal{X}^{(L,1)} = \text{span}(U_i, i \in I)$ ， $\mathcal{X}^{(L,2)} = \text{span}(U_i, i \notin I)$ 。两个序列的可分离性意味着矩阵 \mathbf{X}_I 的列是延时向量 X_1, \dots, X_K 在特征子空间 $\mathcal{X}^{(L,2)}$ 上的投影，恰好是序列 $\mathbb{X}^{(1)}$ 的轨迹矩阵。